

RODRIGO ARAÚJO VIANNINI

POSTECH

IA PARA DEVS

COMPUTER VISION

AULA 06

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON.....	4
SAIBA MAIS.....	5
MERCADO DE TRABALHO, CASES E TENDÊNCIAS.....	20
O QUE VOCÊ VIU NESTA AULA?.....	22
REFERÊNCIAS.....	23

EMANSP

O QUE VEM POR AÍ?

Fala Devs! Nesta aula, vamos imergir no mundo das Redes Neurais Adversativas, as famosas “GANs”, uma das tecnologias mais interessantes e inovadoras no campo da inteligência artificial. Compreenderemos a estrutura básica de uma GAN, sua dinâmica de treinamento e como as redes geradoras e as discriminadoras colaboram para produzir resultados impressionantes na geração de imagens.

Vamos explorar a evolução das arquiteturas GANs, desde os modelos pioneiros como DCGAN e CGAN até as variantes mais avançadas como StyleGAN e BigGAN. Analisaremos como cada avanço arquitetônico impulsionou na qualidade e na diversidade das imagens geradas, bem como seu impacto em várias aplicações, desde arte digital até simulações com foco em realismo.

Em seguida, abordaremos aplicações práticas de GANs em diversas áreas, tais como a geração de imagens médicas para auxílio em diagnóstico, o aumento de dados para treinar modelos de machine learning e até mesmo na criação de ambientes virtuais para jogos, realidade virtual e aumentada.

Uma questão importante a ser debatida é a compreensão dos desafios éticos e de segurança relacionados ao uso de GANs, incluindo questões com viés algorítmicos, manipulação de mídia e preservação da privacidade.

Por fim, vamos explorar técnicas de treinamento e ajuste de hiper parâmetros em GANs, bem como estratégias para lidar com problemas comuns, como o modo “colapso” e a instabilidade de treinamento.

Ao final desta aula, esperamos que você construa uma base sólida no entendimento das Redes Neurais Adversativas, suas aplicações multifacetadas, os desafios inerentes, capacitando-o na exploração das novas fronteiras na criação e manipulação de dados sintéticos de forma criativa e responsável.

HANDS ON

As Redes Neurais Adversativas (GANs) surgiu como uma das tecnologias mais inovadoras e impressionantes no campo da inteligência artificial. Desenvolvida por Ian Goodfellow (2014). As GANs introduziram uma nova abordagem na geração de dados sintéticos com foco em realismo e na resolução de problemas complexos nas mais diversas áreas.



SAIBA MAIS

Definindo as GANs

Em suma, as GANs consistem em dois componentes principais: o **gerador** e o **discriminador**. O gerador é responsável por criar dados sintéticos, como imagens, enquanto o discriminador tenta distinguir ou contrapor entre dados reais e sintéticos. O processo de treinamento das GANs envolve uma competição entre esses dois componentes, onde o gerador busca aprimorar sua capacidade de enganar o discriminador, enquanto o discriminador busca aprimorar sua capacidade de distinguir entre dados reais e sintéticos.

Dinâmica de treinamento e arquitetura básica das redes GANs

Durante o treinamento, o gerador recebe amostras aleatórias de entrada e tenta gerar dados sintéticos que se assemelham aos dados reais. Esses dados sintéticos são então apresentados ao discriminador, juntamente com amostras reais, e o discriminador tenta distinguir entre eles. Com o tempo, o gerador aprende a gerar dados cada vez mais realistas, enquanto o discriminador se torna mais habilidoso em distinguir entre dados reais e sintéticos.

A arquitetura básica de uma GAN consiste em redes neurais profundas, tanto para o gerador quanto para o discriminador. O gerador geralmente utiliza uma arquitetura de rede neural convolucional (CNN) para mapear as entradas aleatórias para dados sintéticos, enquanto o discriminador também pode ser uma CNN projetada para classificar entre dados reais e sintéticos.

Aplicações das redes GANs

As GANs podem ser aplicadas em diversas áreas, incluindo:

- **Geração de imagens realistas:** as GANs são amplamente utilizadas para gerar imagens sintéticas que podem ser indistinguíveis das imagens reais, essas imagens tem aplicação em diversos campos como: design gráfico, cinema, jogos, realidade virtual e aumentada.

- **Transferência de estilo:** as GANs podem ser usadas para transferir estilos de uma imagem para outra, permitindo a criação de obras de arte digitais únicas, exclusivas e impressionantes no que se diz respeito ao realismo.
- **Data augmentation para treinamento de modelos:** as GANs são eficazes no aumento de dados, (geração de dados sintéticos adicionais) para melhorar o desempenho de modelos de machine learning em tarefas de classificação e reconhecimento e reconhecimento de padrões em imagens.
- **Data augmentation para simulação e treinamento em ambientes controlados:** as GANs são usadas em simulações para criar ambientes realistas e controlados para treinamento e teste de sistemas autônomos, como carros autônomos, robôs assistentes dentre outras.
- **Data augmentation para diagnóstico assistido por computador:** as GANs têm sido aplicadas na geração de imagens médicas sintéticas para treinamento de modelos de inteligência artificial em diagnóstico médico, contribuindo para aprimorar a precisão e a eficiência dos sistemas de saúde.

Evolução das arquiteturas de GANs

Desde a sua criação, as Redes Neurais Adversativas (GANs) têm experimentado uma evolução significativa em suas arquiteturas, impulsionada pelas pesquisas contínuas em inteligência artificial. As arquiteturas iniciais foram refinadas, resultando em variantes mais avançadas e com desempenho e capacidades aprimoradas, e essa evolução continua em ritmo acelerado.

Exemplos de GANs:

- **DCGAN (Deep Convolutional GAN):** proposto por Radford et al. (2015), o DCGAN foi uma das primeiras arquiteturas GANs a utilizar camadas convolucionais profundas tanto no gerador quanto no discriminador. Isso permitiu a geração de imagens mais detalhadas e realistas.
- **CGAN (Conditional GAN):** proposto por Mirza e Osindero (2014), o CGAN permite que o gerador e o discriminador recebam informações condicionais

adicionais durante o treinamento. Isso permite a geração condicional de imagens, onde o gerador pode ser controlado para produzir saídas específicas com base em rótulos de classe ou outras características.

- **WGAN (Wasserstein GAN):** proposto por Arjovsky (2017), o WGAN introduziu a noção de “divergência de Wasserstein” como uma métrica de distância entre distribuições de probabilidade. Isso resultou em um treinamento mais estável e com melhores resultados na geração de imagens.
- **StyleGAN:** Proposto por Karras (2018), o StyleGAN introduziu o conceito de controle de estilo em GANs, permitindo a manipulação independente de diferentes aspectos de estilo de imagens geradas, como pose, expressão facial e resolução.
- **BigGAN:** Proposto por Brock (2019), o BigGAN é projetado para escala, permitindo a geração de imagens de alta resolução com qualidade excepcional. Ele também desenvolveu técnicas de condicionamento hierárquico e truncado de espaços latentes para controlar a diversidade e a qualidade das imagens geradas.

Diferenças nas Arquiteturas, vantagens e desvantagens das redes GANs

- **DCGAN:** as vantagens incluem o treinamento estável e a geração de imagens de alta qualidade, já as desvantagens podem incluir limitações na geração condicional e na falta de controle sobre características específicas de imagens.
- **CGAN:** as vantagens incluem a capacidade de geração condicional de imagens, já as desvantagens podem incluir maior complexidade computacional e requisitos adicionais de dados rotulados.
- **WGAN:** as vantagens incluem treinamento mais estável e convergência mais rápida, já as desvantagens podem incluir complexidade adicional na implementação e ajuste de hiperparâmetros.

- **StyleGAN:** as vantagens incluem controle preciso sobre características estilísticas das imagens geradas, já as desvantagens podem incluir maior complexidade na arquitetura e requisitos computacionais mais elevados.
- **BigGAN:** as vantagens incluem geração de imagens de alta resolução com qualidade excepcional, já as desvantagens podem incluir maior complexidade na arquitetura e requisitos computacionais substanciais.

Aplicações das redes GANs

As GANs têm uma ampla variedade de aplicações em diversas áreas, incluindo geração de imagens realistas para design gráfico e entretenimento, geração de dados sintéticos para simulação e treinamento em ambientes controlados, e geração de imagens médicas sintéticas para diagnóstico assistido por computador. As diferentes arquiteturas de GANs podem ser escolhidas com base nas necessidades específicas de cada aplicação, levando em consideração suas vantagens e desvantagens.

As Redes Neurais Adversativas (GANs) têm demonstrado ser uma ferramenta poderosa e versátil em uma ampla gama de aplicações. Abaixo, exploramos algumas das principais aplicações das GANs:

Geração de imagens realistas:

- As GANs são amplamente utilizadas para gerar imagens realistas de pessoas, objetos, paisagens e muito mais.
- Essas imagens podem ser utilizadas em design gráfico, publicidade, produção de filmes, jogos de vídeo, e em muitas outras áreas onde a criação de conteúdo visual é necessária.
- A qualidade impressionante das imagens geradas pelas GANs torna-as uma escolha preferida para produção de conteúdo visual de alta qualidade.

Transferência de estilo:

- As GANs podem ser usadas para transferir o estilo de uma imagem para outra, permitindo a criação de novas imagens que combinam o conteúdo de uma imagem de entrada com o estilo de uma imagem de referência.
- Essa técnica é amplamente utilizada em arte digital, design de moda, e em outras áreas onde a estilização de imagens é importante.

Data augmentation e geração de dados sintéticos para o treinamento de modelos de machine learning:

- As GANs podem ser usadas para gerar dados sintéticos adicionais para treinar modelos de aprendizado de máquina.
- Isso é especialmente útil quando os conjuntos de dados reais são pequenos ou quando é difícil obter dados suficientes para treinamento.
- Ao aumentar a quantidade de dados disponíveis, as GANs ajudam a melhorar o desempenho e a generalização dos modelos de aprendizado de máquina.

Data augmentation e geração de dados sintéticos para simulação e treinamento em ambientes controlados:

- As GANs são utilizadas para gerar dados sintéticos realistas para simulação e treinamento em ambientes controlados.
- Isso é útil em áreas como robótica, automação, e veículos autônomos, onde é necessário simular o comportamento de sistemas em uma variedade de condições.
- Os dados sintéticos gerados pelas GANs ajudam a melhorar a robustez e o desempenho dos sistemas em ambientes do mundo real.

Geração de imagens médicas para diagnóstico assistido por computador:

- As GANs são aplicadas na geração de imagens médicas sintéticas para treinamento de modelos de inteligência artificial em diagnóstico médico.
- Isso inclui a geração de imagens de ressonância magnética, tomografia computadorizada, ultrassom e outras modalidades de imagem.
- As GANs ajudam a melhorar a precisão e a eficiência dos sistemas de saúde, permitindo diagnósticos mais rápidos e precisos.

Ética e segurança

Embora as redes GANs ofereçam benefícios significativos em várias aplicações, também apresentam desafios éticos e de segurança que precisam ser abordados de forma cuidadosa e proativa.

Viés algorítmico em GANs e sua mitigação:

- As GANs podem aprender e perpetuar viés algorítmico presente nos conjuntos de dados de treinamento.
- Isso pode levar a resultados discriminatórios e injustos, especialmente em aplicações sensíveis, como reconhecimento facial e tomada de decisões automatizadas.
- A mitigação do viés algorítmico em GANs requer uma cuidadosa seleção e pré-processamento dos dados de treinamento, além do desenvolvimento de técnicas para identificar e corrigir vieses prejudiciais.

Manipulação de mídia e autenticidade:

- As GANs podem ser usadas para criar imagens e vídeos falsificados com alta qualidade, levantando preocupações sobre a manipulação de mídia e a disseminação de informações falsas.
- Isso pode ter consequências sérias, como difamação, desinformação e comprometimento da confiança pública em conteúdo visual.
- A detecção de mídia manipulada e a garantia de autenticidade tornaram-se áreas de pesquisa ativa, envolvendo o desenvolvimento de métodos de verificação e autenticação de conteúdo visual.

Privacidade e proteção de dados:

- O treinamento de GANs muitas vezes envolve o uso de conjuntos de dados grandes e sensíveis, levantando preocupações com a privacidade e a proteção de dados.
- Há o risco de vazamento de informações pessoais e confidenciais presentes nos dados de treinamento, especialmente em aplicações como geração de imagens médicas e reconhecimento de rostos.
- A proteção da privacidade em aplicações de GANs requer o desenvolvimento de políticas e práticas de segurança robustas, incluindo técnicas de anonimização, criptografia e controle de acesso aos dados.

Treinamento Avançado das redes GANs

O treinamento das redes GANs podem ser desafiadores devido à sua propensão ao colapso do modo, instabilidade e dificuldade na convergência. Abordar esses problemas requer estratégias avançadas, técnicas de regularização e normalização, bem como um ajuste cuidadoso dos hiperparâmetros para otimizar o desempenho da GAN.

Estratégias para prevenir o colapso do modo e a instabilidade do treinamento:

- **Diversidade de dados de treinamento:** garantir que o conjunto de dados de treinamento seja diversificado e representativo ajuda a evitar que a GAN se concentre em um número limitado de modos de distribuição.
- **Aprimoramento do discriminador:** fortalecer o discriminador por meio de treinamento prévio ou técnicas de aumento de dados pode ajudar a evitar que ele seja facilmente enganado pelo gerador.
- **Atualização balanceada dos parâmetros:** alternar entre atualizações do gerador e do discriminador de forma balanceada durante o treinamento pode ajudar a evitar que um componente domine o outro.

Técnicas de regularização e normalização:

- **Regularização L1/L2:** adicionar termos de regularização L1 ou L2 às perdas do gerador e do discriminador pode ajudar a evitar o sobreajuste e melhorar a generalização.
- **Normalização de batch:** aplicar normalização de batch nas camadas da GAN pode estabilizar o treinamento, melhorar a convergência e reduzir a dependência da inicialização dos pesos.
- **Regularização espectral:** regularização espectral pode ser aplicada às matrizes de pesos das camadas da GAN para promover uma melhor condição numérica durante o treinamento.

Ajuste de hiper parâmetros e otimização de desempenho:

- **Taxa de aprendizado adaptativa:** utilizar taxas de aprendizado adaptativas, como a taxa de aprendizado cíclica ou a taxa de aprendizado

programada, pode ajudar a evitar problemas de otimização durante o treinamento da GAN.

- **Busca em grade de hiperparâmetros:** realizar uma busca em grade de hiperparâmetros, incluindo taxas de aprendizado, tamanho do lote, número de camadas e outros parâmetros, pode ajudar a encontrar uma configuração ideal para a GAN.
- **Validação cruzada:** usar validação cruzada para avaliar diferentes configurações de hiperparâmetros pode ajudar a escolher a melhor combinação para otimizar o desempenho da GAN.

Implementação de uma GAN Simples

Agora, vamos colocar em prática os conceitos aprendidos até o momento, vamos implementar uma GAN simples utilizando o framework TensorFlow. Nosso objetivo é gerar imagens de dígitos manuscritos, como os presentes no conjunto de dados MNIST, e experimentar com diferentes arquiteturas e parâmetros para entender seu impacto na geração de imagens.

Passo-a-passo:

Preparação do ambiente:

- Instale o TensorFlow em seu ambiente de desenvolvimento.
- Importe as bibliotecas necessárias, como TensorFlow, NumPy e Matplotlib.

Carregamento e pré-processamento dos dados:

- Carregue o conjunto de dados MNIST contendo imagens de dígitos manuscritos.
- Normalize as imagens para o intervalo $[-1, 1]$ e redimensione, se necessário.

Definição da arquitetura da GAN:

- Crie as redes neurais para o gerador e o discriminador.
- Experimente com diferentes arquiteturas, como redes neurais convolucionais (CNNs) simples.

Treinamento da GAN:

- Defina a função de perda para a GAN, incluindo a perda adversarial e a perda de reconstrução, se aplicável.
- Configure os otimizadores para o gerador e o discriminador.
- Treine a GAN em lotes de imagens do conjunto de dados MNIST.

Avaliação e experimentação:

- Avalie a qualidade das imagens geradas durante o treinamento, visualizando amostras periodicamente.
- Experimente com diferentes arquiteturas e parâmetros, como o número de camadas, tamanho do lote e taxa de aprendizado.
- Compare os resultados e observe o impacto na qualidade das imagens geradas.

Análise de resultados:

- Analise os resultados obtidos com diferentes configurações e parâmetros.
- Observe como mudanças na arquitetura e nos hiperparâmetros afetam a capacidade da GAN de gerar imagens realistas.

Conclusão e discussão:

- Faça uma conclusão sobre as descobertas do laboratório.
- Discuta os desafios encontrados, as lições aprendidas e possíveis melhorias para futuras experimentações.

Vamos codar...

Importando as bibliotecas necessárias:

```
1 import tensorflow as tf
2 from tensorflow.keras import layers, models
3 import numpy as np
4 import matplotlib.pyplot as plt
```

Figura 1 - Código (1)
Fonte: Elaborado pelo autor (2024)

Carregando as imagens e realizando o pré-processamento dos dados:

```

1 # Carregar e pré-processar os dados
2 (train_images, _), (_, _) = tf.keras.datasets.mnist.load_data()
3 train_images = (train_images.astype('float32') - 127.5) / 127.5 # Normalizar para o intervalo [-1, 1]
4 train_images = np.expand_dims(train_images, axis=-1)

```

Figura 2 - Código (2)
Fonte: Elaborado pelo autor (2024)

Definindo o gerador:

```

1 # Definir o gerador
2 def make_generator_model():
3     models.Sequential().add(layers.Dense(7*7*256, use_bias=False, input_shape=(100,)))
4     models.Sequential().add(layers.BatchNormalization())
5     models.Sequential().add(layers.LeakyReLU())
6
7     models.Sequential().add(layers.Reshape((7, 7, 256)))
8     models.Sequential().add(layers.Conv2DTranspose(128, (5, 5), strides=(1, 1),
9     padding='same', use_bias=False))
10    models.Sequential().add(layers.BatchNormalization())
11    models.Sequential().add(layers.LeakyReLU())
12
13    models.Sequential().add(layers.Conv2DTranspose(64, (5, 5), strides=(2, 2),
14    padding='same', use_bias=False))
15    models.Sequential().add(layers.BatchNormalization())
16    models.Sequential().add(layers.LeakyReLU())
17
18    models.Sequential().add(layers.Conv2DTranspose(1, (5, 5), strides=(2, 2),
19    padding='same', use_bias=False,
20    activation='tanh'))
21
22    return models.Sequential()

```

Figura 3 - Código (3)
Fonte: Elaborado pelo autor (2024)

Definindo o discriminador:

```

1 # Definir o discriminador
2 def make_discriminator_model():
3     model = models.Sequential()
4     model.add(layers.Conv2D(64, (5, 5), strides=(2, 2),
5     padding='same', input_shape=[28, 28, 1]))
6     model.add(layers.LeakyReLU())
7     model.add(layers.Dropout(0.3))
8
9     model.add(layers.Conv2D(128, (5, 5), strides=(2, 2),
10    padding='same'))
11    model.add(layers.LeakyReLU())
12    model.add(layers.Dropout(0.3))
13
14    model.add(layers.Flatten())
15    model.add(layers.Dense(1))
16
17    return model

```

Figura 4 - Código (4)
Fonte: Elaborado pelo autor (2024)

Definindo a função de perda e otimizadores:

```

1 # Definir a função de perda e otimizadores
2 cross_entropy = tf.keras.losses.BinaryCrossentropy(from_logits=True)
3
4 def discriminator_loss(real_output, fake_output):
5     real_loss = cross_entropy(tf.ones_like(real_output), real_output)
6     fake_loss = cross_entropy(tf.zeros_like(fake_output), fake_output)
7     total_loss = real_loss + fake_loss
8     return total_loss
9
10 def generator_loss(fake_output):
11     return cross_entropy(tf.ones_like(fake_output), fake_output)
12
13 generator_optimizer = tf.keras.optimizers.Adam(1e-4)
14 discriminator_optimizer = tf.keras.optimizers.Adam(1e-4)

```

Figura 5 - Código (5)

Fonte: Elaborado pelo autor (2024)

Definindo o treinamento:

```

1 # Definir o treinamento
2 EPOCHS = 100
3 BATCH_SIZE = 256
4 noise_dim = 100
5 num_examples_to_generate = 16
6
7 generator = make_generator_model()
8 discriminator = make_discriminator_model()

```

Figura 6 - Código (6)

Fonte: Elaborado pelo autor (2024)

```

1 @tf.function
2 def train_step(images):
3     noise = tf.random.normal([BATCH_SIZE, noise_dim])
4
5     with tf.GradientTape() as gen_tape, tf.GradientTape() as disc_tape:
6         generated_images = generator(noise, training=True)
7
8         real_output = discriminator(images, training=True)
9         fake_output = discriminator(generated_images, training=True)
10
11         gen_loss = generator_loss(fake_output)
12         disc_loss = discriminator_loss(real_output, fake_output)
13
14         gradients_of_generator = gen_tape.gradient(gen_loss, generator.trainable_variables)
15         gradients_of_discriminator = disc_tape.gradient(disc_loss,
16                                                         discriminator.trainable_variables)
17
18         generator_optimizer.apply_gradients(zip(gradients_of_generator, generator.trainable_variables))
19         discriminator_optimizer.apply_gradients(zip(gradients_of_discriminator,
20                                                    discriminator.trainable_variables))

```

Figura 7 - Código (7)

Fonte: Elaborado pelo autor (2024)

```

1 # Treinamento da GAN
2 def train(dataset, epochs):
3     for epoch in range(epochs):
4         for image_batch in dataset:
5             train_step(image_batch)

```

Figura 8 - Código (8)
Fonte: Elaborado pelo autor (2024)

Treinamento e geração das imagens:

```

1 # Geração de imagens
2 def generate_and_save_images(model, epoch, test_input):
3     predictions = model(test_input, training=False)
4
5     fig = plt.figure(figsize=(4,4))
6
7     for i in range(predictions.shape[0]):
8         plt.subplot(4, 4, i+1)
9         plt.imshow(predictions[i, :, :, 0] * 127.5 + 127.5, cmap='gray')
10        plt.axis('off')
11
12    plt.savefig('image_at_epoch_{:04d}.png'.format(epoch))
13    plt.show()
14
15 # Treinamento e geração de imagens
16 def train_and_generate_images(dataset, epochs):
17     for epoch in range(epochs):
18         train(dataset, epochs)
19         generate_and_save_images(generator, epoch + 1, seed)
20
21 # Treinamento e geração de imagens
22 train_dataset = tf.data.Dataset.from_tensor_slices(train_images).shuffle(len(train_images)).batch(BATCH_SIZE)
23 train_and_generate_images(train_dataset, EPOCHS)

```

Figura 9 - Código (9)
Fonte: Elaborado pelo autor (2024)

Output:



Figura 9 - Output (1)
Fonte: Elaborado pelo autor (2024)



Figura 10 - Output (2)
Fonte: Elaborado pelo autor (2024)

Confira o resultado do treinamento e as comparações das imagens [aqui](#)

Novas tendências:

- **Melhoria da estabilidade e convergência:** os pesquisadores estão trabalhando para melhorar a estabilidade e a convergência das GANs, reduzindo problemas como o colapso do modo e a oscilação do treinamento.
- **Controle e interpretabilidade:** há um interesse crescente em desenvolver métodos que permitam maior controle sobre a geração de imagens pelas GANs, bem como tornar seus processos mais interpretáveis e compreensíveis.
- **Aplicações multimodais:** as GANs estão sendo exploradas para gerar conteúdo multimodal, como imagens acompanhadas de texto descritivo ou música combinada com imagens, ampliando suas capacidades para além da geração de imagens simples.
- **Aprendizado não supervisionado e autoencoder:** o desenvolvimento de GANs que possam aprender representações latentes úteis e eficientes sem supervisão é uma área de pesquisa promissora, com potencial para aplicações em reconstrução de imagens e compressão de dados.

Novos desafios:

- **Design de produtos e imagens personalizadas:** as GANs têm o potencial de revolucionar a indústria do design, permitindo a criação de produtos personalizados e imagens sob medida de acordo com as preferências do usuário.
- **Medicina personalizada e simulação biomédica:** GANs podem ser aplicadas na geração de imagens médicas sintéticas para treinamento de modelos de diagnóstico, simulação de procedimentos cirúrgicos e criação de terapias personalizadas.
- **Música e artes visuais generativas:** as GANs podem ser utilizadas na geração de música original e arte visual, explorando novas formas de expressão criativa e colaboração entre humanos e máquinas.
- **Desafios de ética e viés:** o uso generalizado de GANs levanta questões éticas importantes relacionadas à autoria, privacidade e potencial viés nos dados gerados, exigindo uma reflexão cuidadosa e regulamentação adequada. Com uma abordagem cuidadosa e colaborativa, as GANs têm o potencial de impulsionar avanços significativos na inteligência artificial e na aprendizagem de máquina, contribuindo para um futuro mais inteligente, criativo e inclusivo.

O papel das GANs na evolução da inteligência artificial e da aprendizagem de máquina:

As GANs desempenham um papel crucial na evolução da inteligência artificial e da aprendizagem de máquina, contribuindo para avanços significativos em várias áreas:

- **Geração de dados sintéticos:** as GANs permitem a geração de dados sintéticos realistas, possibilitando o treinamento de modelos em larga escala mesmo em casos onde dados reais são escassos ou difíceis de obter.
- **Entendimento e manipulação de dados complexos:** as GANs ajudam a entender e manipular dados complexos, como imagens, áudio e texto, fornecendo ferramentas poderosas para análise e síntese de informações.

- **Avanços em aprendizado não supervisionado:** as GANs impulsionam o desenvolvimento de técnicas de aprendizado não supervisionado, permitindo a descoberta automática de padrões e representações úteis nos dados, sem a necessidade de rotulagem manual.
- **Inovação criativa e expressiva:** as GANs abrem novas fronteiras na criação artística e inovação criativa, proporcionando novas ferramentas para artistas e designers explorarem novos conceitos e formas de expressão.

EMANIP

MERCADO, CASES E TENDÊNCIAS

O mercado de trabalho atual e futuro está passando por transformações significativas impulsionadas pela rápida evolução da tecnologia, mudanças nas demandas da economia global e novos paradigmas de trabalho.

Digitalização e Automação:

- A digitalização e automação de processos estão se tornando cada vez mais comuns em todos os setores, resultando na demanda por profissionais com habilidades em tecnologias digitais, como ciência de dados, inteligência artificial, automação de processos robóticos (RPA) e desenvolvimento de software. Além disso, a inteligência artificial e a automação continuarão a impactar o mercado de trabalho, substituindo algumas funções tradicionais.

Trabalho Remoto e Flexibilidade:

- A pandemia COVID-19 acelerou a adoção do trabalho remoto e a tendência deve continuar no futuro. Isso cria oportunidades para profissionais que podem trabalhar de forma eficaz em ambientes remotos e adaptáveis a diferentes modelos de trabalho flexíveis.

Aprendizado Contínuo e Reskilling:

- Com as rápidas mudanças tecnológicas, a capacidade de aprendizado contínuo e reskilling se torna essencial para os profissionais permanecerem relevantes no mercado de trabalho. Isso inclui a busca por certificações, cursos on-line e atualizações regulares de habilidades.

Economia Digital e Freelancers:

- A economia digital está criando oportunidades para freelancers e trabalhadores independentes em áreas como design gráfico, desenvolvimento de aplicativos, marketing digital e consultoria especializada. Plataformas para encontrar freelancers on-line estão se tornando cada vez mais populares.

Sustentabilidade e Responsabilidade Social:

- As preocupações com sustentabilidade e responsabilidade social estão moldando as práticas de negócios e criando demanda por profissionais com habilidades em áreas como energias renováveis, gestão ambiental, ética empresarial e desenvolvimento sustentável.

Setores Emergentes

- Setores emergentes, como tecnologia blockchain, realidade virtual/aumentada, biotecnologia, saúde digital e mobilidade sustentável, estão oferecendo oportunidades de carreira para profissionais com conhecimentos nessas áreas.

Envelhecimento da População e Cuidados de Saúde:

- Com o envelhecimento da população, há uma crescente demanda por profissionais de saúde, cuidados de idosos e tecnologias de assistência, bem como serviços relacionados ao bem-estar, como terapia ocupacional, coaching de saúde e nutrição.

Economia Circular e Sustentável:

- Com a crescente conscientização sobre questões ambientais, a economia circular e sustentável está se tornando uma prioridade para muitas empresas e governos, criando oportunidades para profissionais com conhecimentos em gestão de resíduos, design sustentável, energia limpa e economia verde.

Em resumo, o mercado de trabalho atual e futuro estão evoluindo exponencialmente, oferecendo oportunidades para profissionais adaptáveis, com habilidades diversas, os quais possuem uma capacidade de aprendizado contínuo e consciência das tendências globais e locais. Aqueles que estão dispostos a se manterem atualizados e investir em seu desenvolvimento profissional têm o potencial de prosperar em um ambiente de trabalho moderno.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula falamos sobre o conceito das Redes Neurais Adversativas, conhecidas pelo prefixo GAN. Elas são responsáveis por criar dados sintéticos para os mais diversos fins. Exploramos as questões técnicas como: hiperparâmetros, os conceitos de gerador e discriminador e sua concorrência em prol do resultado. Também passeamos pelos conceitos gerais, tais como: as primeiras redes GANs, suas aplicações, mercado de trabalho, desafios e tendências.

Por fim, treinamos um modelo de GAN simples, usando um dataset nativo da biblioteca TensorFlow e plotamos uma amostra do output, com um link do github onde pudemos explorar todas as saídas e comparar as imagens reais e sintéticas.

REFERÊNCIAS

- BROCK, A.; DONAHUE, J.; SIMONYAN, K. **Large Scale GAN Training for High Fidelity Natural Image Synthesis**. 2018. Disponível em: <https://arxiv.org/abs/1809.11096>. Acesso em: 22 jul. 2024.
- CHOLLET, F. **Deep Learning with Python**. Nova Iorque: Manning Publications, 2017.
- GÉRON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow**. Massachusetts: O'Reilly Media, 2019.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. Massachusetts: MIT Press, 2016.
- GULRAJANI, I.; AHMED, F.; ARJOVSKY, M.; DUMOULIN, V.; COURVILLE, A. C. **Improved Training of Wasserstein GANs**. In: Advances in Neural Information Processing Systems 30. 2017. Disponível em: <https://arxiv.org/abs/1704.00028>. Acesso em: 22 jul. 2024.
- HE, K.; ZHANG, X.; REN, S.; SUN, J. **Deep Residual Learning for Image Recognition**. In: CVPR, 2016.
- KARRAS, T.; LAINE, S.; AILA, T. A **Style-Based Generator Architecture for Generative Adversarial Networks**. 2018. Disponível em: <https://arxiv.org/abs/1812.04948>. Acesso em: 22 jul. 2024.
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. **ImageNet Classification with Deep Convolutional Neural Networks**. In: NIPS, 2012.
- MIRZA, M.; OSINDERO, S. **Conditional Generative Adversarial Nets**. 2014. Disponível em: <https://arxiv.org/abs/1411.1784>. Acesso em: 22 jul. 2024.
- RADFORD, A.; METZ, L.; CHINTALA, S. **Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks**. 2015. Disponível em: <https://arxiv.org/abs/1511.06434>. Acesso em: 22 jul. 2024.
- SZEGEDY, C.; LIU, W.; JIA, Y., et al. **Going Deeper with Convolutions**. In: CVPR, 2015.

PALAVRAS-CHAVE

Redes Neurais Convolucionais, CNNs, Generative Adversarial Networks, GANs, Arquiteturas de GANs, Aplicações de GANs, Visão Computacional, Aprendizado de Máquina.

EMENDAS



POSTECH