

**FIAP - Faculdade de Informática e Administração
Paulista**

Pós-Graduação em IA para Devs

Tech Challenge 1

André Pires de Oliveira Capela - rm376905

Setembro de 2026

Recursos:

Git: <https://github.com/AndrCapela/Tech-Challenge-1>

Vídeo: https://youtu.be/8su3_PFxJpU

Introdução

Este notebook documenta a resolução do desafio prático de Machine Learning desenvolvido para a Fase 1 do curso de Inteligência Artificial para Desenvolvedores da FIAP. O objetivo central deste trabalho é construir um modelo preditivo capaz de analisar dados clínicos e diagnosticar tumores mamários, classificando-os de forma precisa entre Benignos (B) e Malignos (M).

A base de dados tabular utilizada neste estudo é composta por 569 amostras e 30 atributos numéricos independentes, que descrevem características celulares e espaciais dos tumores (como raio, textura, perímetro, área, suavidade, entre outros). O pipeline inicial do projeto abrange a limpeza dos dados (como a remoção de colunas nulas e identificadores) e uma profunda análise gráfica e de correlação. Identificou-se que atributos espaciais, como raio e área, possuem altíssima correlação, o que exige atenção especial ao *overfitting* devido à alta dimensionalidade frente ao volume de amostras. Para mitigar esses desafios, exploramos técnicas de transformação como ajustes de escala (StandardScaler e MinMaxScaler) e redução de dimensionalidade (PCA).

A fase de modelagem avalia o desempenho de uma suíte robusta de algoritmos, incluindo Regressão Logística, KNN, Random Forest, XGBoost e SVM. Contudo, o verdadeiro rigor deste projeto reside na sua aplicação médica. No ecossistema de saúde, os erros preditivos possuem pesos desiguais: um Falso Negativo (classificar um tumor maligno como benigno) tem um custo inaceitável e potencialmente fatal, pois impede o tratamento precoce do paciente.

Por essa razão, a conclusão metodológica deste trabalho prioriza a otimização do *Recall* (Sensibilidade) para a classe maligna. Demonstraremos como a calibração de hiperparâmetros e a penalização matemática de classes desbalanceadas (como o ajuste manual de `class_weight`) são fundamentais para criar não apenas um modelo com alta acurácia estatística, mas uma ferramenta clinicamente segura e viável.

Análise de dados

O processo de Análise Exploratória de Dados (EDA) e análise gráfica é uma etapa crítica para compreender a estrutura, a distribuição e os relacionamentos inerentes aos dados

oncológicos fornecidos. Através da inspeção inicial e da representação visual, extraímos *insights* que fundamentam as decisões de pré-processamento e modelagem preditiva.

Limpeza e Consistência

A verificação estrutural confirmou que todas as variáveis independentes são numéricas (float64) e não possuem dados faltantes, com exceção da coluna Unnamed: 32, que era composta inteiramente por valores nulos e foi descartada junto com a coluna id, que não possui poder preditivo.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 33 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   id                                    569 non-null    int64
1   diagnosis                            569 non-null    object
2   radius_mean                          569 non-null    float64
3   texture_mean                         569 non-null    float64
4   perimeter_mean                      569 non-null    float64
5   area_mean                           569 non-null    float64
6   smoothness_mean                     569 non-null    float64
7   compactness_mean                    569 non-null    float64
8   concavity_mean                      569 non-null    float64
9   concave points_mean                 569 non-null    float64
10  symmetry_mean                       569 non-null    float64
11  fractal_dimension_mean              569 non-null    float64
12  radius_se                           569 non-null    float64
13  texture_se                           569 non-null    float64
14  perimeter_se                        569 non-null    float64
15  area_se                             569 non-null    float64
16  smoothness_se                       569 non-null    float64
17  compactness_se                      569 non-null    float64
18  concavity_se                        569 non-null    float64
19  concave points_se                   569 non-null    float64
20  symmetry_se                         569 non-null    float64
21  fractal_dimension_se                569 non-null    float64
22  radius_worst                        569 non-null    float64
23  texture_worst                       569 non-null    float64
24  perimeter_worst                     569 non-null    float64
25  area_worst                          569 non-null    float64
26  smoothness_worst                    569 non-null    float64
27  compactness_worst                   569 non-null    float64
28  concavity_worst                     569 non-null    float64
29  concave points_worst                569 non-null    float64
30  symmetry_worst                      569 non-null    float64
31  fractal_dimension_worst              569 non-null    float64
32  Unnamed: 32                          0 non-null      float64
dtypes: float64(31), int64(1), object(1)
memory usage: 146.8+ KB
```

Análise de Dispersão e Escala

O resumo estatístico evidenciou uma amplitude de dados altamente heterogênea entre as *features*. Essa enorme disparidade matemática torna mandatória a aplicação de algoritmos


de reescala (como *StandardScaler* ou *MinMaxScaler*) antes do treinamento de modelos sensíveis a distâncias ou gradientes (como KNN e SVM).

	id	radius_mean	texture_mean	perimeter_mean	area_mean	smoothness_mean	compactness_mean	concavity_mean	concave points_mean	symmetry_mean	...
count	5.690000e+02	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	569.000000	...
mean	3.037183e+07	14.127292	19.289649	91.969033	654.889104	0.096360	0.104341	0.088799	0.048919	0.181162	...
std	1.250206e+08	3.524049	4.301036	24.298981	351.914129	0.014064	0.052813	0.079720	0.038803	0.027414	...
min	8.670000e+03	6.981000	9.710000	43.790000	143.500000	0.052630	0.019380	0.000000	0.000000	0.106000	...
25%	8.692180e+05	11.700000	16.170000	75.170000	420.300000	0.086370	0.064920	0.029560	0.020310	0.161900	...
50%	9.060240e+05	13.370000	18.840000	86.240000	551.100000	0.095870	0.092630	0.061540	0.033500	0.179200	...
75%	8.813129e+06	15.780000	21.800000	104.100000	782.700000	0.105300	0.130400	0.130700	0.074000	0.195700	...
max	9.113205e+08	28.110000	39.280000	188.500000	2501.000000	0.163400	0.345400	0.426800	0.201200	0.304000	...

8 rows x 32 columns

Multicolinearidade e Matriz de Correlação

A matriz de correlação revelou um alto grau de dependência linear entre diversas características geométricas do tumor. Atributos como radius_mean, perimeter_mean e area_mean apresentam coeficientes de correlação extremamente fortes, muito próximos a 1.0. Esta forte multicolinearidade pode prejudicar algoritmos lineares e sinaliza que técnicas de redução de dimensionalidade (como PCA) podem ser úteis para enxugar o espaço de features sem perda severa de informação.



Distribuição Gráfica (Histogramas)

A geração dos histogramas individuais para as 30 variáveis numéricas permite avaliar visualmente o comportamento das distribuições. É possível identificar atributos que seguem uma distribuição normal e outros que apresentam forte assimetria (*skewness*) ou caudas longas. Considerando a proporção de 30 variáveis preditoras para apenas 569 amostras, a visualização gráfica reforça a necessidade de controle rigoroso contra o *overfitting* nas etapas de treinamento.

Modelagem Preditiva e Avaliação de Resultados

Nesta etapa do projeto, a estratégia de modelagem envolveu a implementação e comparação de uma suíte robusta de algoritmos de *Machine Learning* para garantir a melhor aderência aos dados oncológicos. Através das bibliotecas scikit-learn e xgboost, os seguintes modelos foram avaliados:

- **Regressão Logística:** Aplicada como um excelente *baseline* linear, oferecendo alta interpretabilidade para a compreensão inicial dos dados.
- **K-Nearest Neighbors (KNN):** Utilizado como uma abordagem não paramétrica, porém demonstrou ser muito sensível à maldição da dimensionalidade devido ao alto número de *features* em relação ao volume de amostras.
- **Random Forest:** Este algoritmo de *Ensemble (Bagging)* foi empregado por sua capacidade de lidar bem com relacionamentos não lineares e com a multicolinearidade dos dados espaciais do tumor, operando com eficácia sem a necessidade estrita de escalonamento numérico.
- **XGBoost (Extreme Gradient Boosting):** Sendo um algoritmo avançado de impulsionamento baseado em árvores de decisão, destacou-se pela velocidade de convergência e excelente generalização no conjunto de teste. Mostrou-se extremamente robusto para capturar padrões sutis que os modelos lineares acabaram perdendo.


Otimização Clínica e o Desempenho do Support Vector Machine (SVM)

O grande diferencial tecnológico e clínico deste trabalho consistiu na interpretação das métricas de erro. Na área da saúde, o custo de um Falso Negativo (classificar um tumor maligno como benigno) é potencialmente fatal, enquanto um Falso Positivo acarreta custos e estresse, mas não ameaça a vida do paciente de forma imediata.

Para ilustrar essa dinâmica, o algoritmo **Support Vector Machines (SVM)**, que busca o hiperplano de separação máxima utilizando *kernels* não lineares (como o RBF), foi treinado sob duas perspectivas diferentes:

1. Desempenho do Modelo SVM Não Balanceado

Inicialmente, o modelo foi treinado com hiperparâmetros padrão e sem ajustes de peso. O algoritmo tendeu a favorecer a classe majoritária (Benigno), resultando na seguinte Matriz de Confusão:




Apesar de uma Acurácia global aparentemente boa, o modelo deixou passar 4 casos malignos, um erro intolerável na produção clínica, pois pacientes seriam liberados equivocadamente sem tratamento.

2. Otimização Direcionada e Ajuste de Função de Custo

Para suprimir a perigosa taxa de Falsos Negativos, a abordagem estratégica mudou para maximizar o *Recall* (Sensibilidade) da classe Maligna. Em vez de utilizar os pesos padrão, a função de custo do classificador foi matematicamente alterada para tratar a classe maligna com uma importância cinco vezes maior (`class_weight={'B': 1, 'M': 5}`).

Essa alteração drástica obrigou a fronteira de decisão a se deslocar para capturar o maior número possível de instâncias da classe maligna, terminando com um resultado de:



Relatório de Classificação:

	precision	recall	f1-score	support
B	0.97	0.97	0.97	72
M	0.95	0.95	0.95	42
accuracy			0.96	114
macro avg	0.96	0.96	0.96	114
weighted avg	0.96	0.96	0.96	114

Falsos Negativos Anteriores: 4
Falsos Negativos Atuais: 2

Comparativo Final de Modelos Otimizados

Ao final desta análise, comparamos as versões dos modelos configuradas especificamente para evitar o erro mais caro no diagnóstico (Falsos Negativos):

- **SVM Sensível (Peso 5): 2 Falsos Negativos** | 2 Falsos Positivos | Acurácia 96.49%
- **XGBoost Sensível (Peso 100): 1 Falso Negativo** | 3 Falsos Positivos | Acurácia 96.49%

O ajuste de pesos provou ser a técnica mais poderosa para customizar a segurança do diagnóstico. O **XGBoost (Peso 100)** oferece a proteção máxima contra omissões de diagnóstico (apenas 1 erro), enquanto o **SVM (Peso 5)** apresenta um equilíbrio notável com apenas 2 erros de cada tipo. Ambos os modelos são superiores à configuração padrão para uso em triagem médica.

Ao aplicar pesos de classe tanto no SVM quanto no XGBoost, observamos se um dos modelos consegue errar ainda menos na detecção de tumores malignos. Geralmente, o

SVM Linear mantém uma fronteira mais estável em conjuntos pequenos, mas o XGBoost oferece flexibilidade para capturar nuances se o peso for bem ajustado.

Parte 2 - Visão Computacional e Diagnóstico por Imagens

Mamográficas

Introdução

Este notebook documenta a segunda etapa do projeto prático de Machine Learning para a Fase 1 do curso de Inteligência Artificial para Desenvolvedores da FIAP. Enquanto a primeira fase focou na análise de dados estruturados (tabulares), este desafio eleva a complexidade ao aplicar técnicas avançadas de Visão Computacional na análise de dados não-estruturados: imagens médicas.

O objetivo central é construir uma Rede Neural Convolucional (CNN) capaz de analisar milhares de recortes de radiografias mamárias (formato JPEG) que contêm anomalias como massas e calcificações, classificando-as com precisão entre exames Benignos (0) e Malignos (1).

Trabalhar com imagens médicas em alta resolução exige um rigor arquitetônico e computacional considerável. Para resolver este desafio, o desenvolvimento foi estruturado sob os seguintes pilares tecnológicos e metodológicos:

- **Prevenção de Vazamento de Dados (Data Leakage):** A base é composta por mais de 3.500 imagens distribuídas entre 1.566 pacientes únicos. Utilizamos a técnica de *GroupShuffleSplit* para garantir que todas as imagens de um mesmo paciente permaneçam exclusivamente no conjunto de treino ou no de teste, evitando que o modelo "decore" características anatômicas específicas do indivíduo.
- **Pipeline de Dados Altamente Otimizado:** Devido ao peso dos arquivos de imagem, carregá-los integralmente na memória RAM resultaria em estouro de memória (Out of Memory - OOM). Implementamos um pipeline dinâmico utilizando *tf.data.Dataset*, que carrega e pré-processa as imagens diretamente do disco em pequenos lotes (*batches*) e de forma assíncrona (*prefetching*), garantindo eficiência e rapidez durante o treinamento na GPU.
- **Aumento de Dados (Data Augmentation):** Para construir um modelo robusto e evitar o *overfitting*, aplicamos transformações matemáticas aleatórias nos dados de treino (como rotações, espelhamentos, zoom e translações). Destaca-se a variação aleatória de contraste, crucial em radiografias devido à densidade variável do tecido mamário (mamas mais densas ou gordurosas).

- **Transfer Learning e Fine-Tuning com EfficientNetB3:** Em vez de treinar uma rede do zero (inicialmente foi feito mas o resultado deixou a desejar), importamos a poderosa arquitetura *EfficientNetB3*, previamente treinada em milhões de imagens, aproveitando sua capacidade nativa de detectar bordas e padrões complexos. Removemos a camada de classificação genérica original e acoplamos um cabeçalho customizado (com *GlobalAveragePooling*, *BatchNormalization* e *Dropout*). Por fim, aplicamos o *Fine-Tuning*, descongelando a rede base e utilizando uma taxa de aprendizado extremamente baixa ($1e-4$) para que a IA adapte seus pesos sutilmente às texturas vitais e microcalcificações dos tumores.

Este documento detalha passo a passo a construção dessa arquitetura, desde o tratamento dos metadados e o fluxo de tensores, até a compilação final do modelo focado em métricas clínicas essenciais como Acurácia e AUC (Área sob a Curva ROC).

Preparação dos Dados e Construção do Modelo CNN

O tratamento de exames de imagem exige cuidados redobrados tanto na validação metodológica quanto na otimização computacional. Nesta etapa, detalhamos o fluxo de preparação das radiografias mamárias e a montagem da arquitetura de inteligência artificial.

2.1. Divisão Estratégica dos Dados (Prevenção de Vazamento)

Em bases de dados médicas, é comum que um único paciente possua múltiplas imagens (diferentes ângulos ou recortes do mesmo exame). Uma divisão aleatória simples poderia colocar imagens do mesmo paciente tanto no conjunto de treino quanto no de teste, causando o chamado vazamento de dados (*Data Leakage*). Nesse cenário, o modelo poderia "decorar" a anatomia do paciente em vez de aprender a identificar a anomalia.

Para garantir a integridade da validação, aplicamos a classe `GroupShuffleSplit` agrupando as amostras pelo `patient_id`. Isso assegurou que as imagens de um mesmo indivíduo fossem alocadas inteiramente para treinamento ou inteiramente para teste (proporção de 80/20), resultando em 2.873 imagens de treino e 694 de teste.


2.2. Pré-processamento e Pipeline Dinâmico (tf.data)

Imagens médicas em alta resolução consomem grande quantidade de memória. O carregamento estático de todas as amostras na memória RAM resultaria em falhas por falta de recursos (*Out of Memory*). A solução implementada foi a construção de um pipeline de dados dinâmico utilizando a API `tf.data.Dataset` do TensorFlow.

A função de pré-processamento criada executa as seguintes operações sob demanda:

1. Leitura do arquivo do disco como string de bytes e decodificação para um tensor RGB.
2. Redimensionamento padronizado para **300x300 pixels**, resolução escolhida para permitir que o modelo capture texturas e microcalcificações com alto nível de detalhe.
3. Conversão dos pixels para o formato `float32`.

Para otimizar o fluxo entre CPU e GPU, o pipeline foi configurado com paralelismo (`num_parallel_calls=tf.data.AUTOTUNE`), agrupamento em lotes (`batch(32)`) e *prefetching*, permitindo que a CPU processe o próximo lote de imagens enquanto a GPU treina o lote atual.



2.3. Data Augmentation (Aumento de Dados)

Com o intuito de evitar o *overfitting* — situação onde a rede neural apenas memoriza os dados de treino — foi introduzida uma camada inicial no modelo contendo operações de *Data Augmentation*. Foram aplicadas transformações matemáticas aleatórias, com justificativas clínicas específicas:

- **Espelhamento e Rotação (até 20%):** A orientação biológica de um nódulo isolado não altera seu diagnóstico, simulando variações de posicionamento no mamógrafo.
- **Zoom e Translação (10% a 20%):** Previne que o modelo presuma que a anomalia estará sempre perfeitamente centralizada na imagem.
- **Contraste Aleatório (20%):** Crucial para mamografias, pois a variação na densidade do tecido mamário (mamas mais densas ou gordurosas) produz radiografias nativamente mais claras ou mais escuras.

2.4. Arquitetura da CNN: Transfer Learning e Fine-Tuning


A construção da Rede Neural baseou-se na técnica de *Transfer Learning* utilizando a arquitetura profunda **EfficientNetB3**, previamente treinada no *ImageNet*. O processo foi estruturado da seguinte forma:

1. **Importação e Adaptação:** A camada de classificação original foi removida (`include_top=False`), permitindo aproveitar a poderosa capacidade nativa da EfficientNet para detecção de bordas e texturas.
2. **Cabeçalho Customizado:** Plugamos um novo cabeçalho de classificação composto por uma camada `GlobalAveragePooling2D` (para converter as matrizes 2D em um vetor 1D), seguida de `BatchNormalization` para estabilizar o aprendizado. Inserimos camadas `Dense` (128 neurônios) intercaladas com `Dropout` (taxa de 0.3) para forçar a rede a não depender de pixels específicos. A saída final consiste em um único neurônio com ativação `sigmoid`, gerando uma probabilidade estatística entre Benigno e Maligno.
3. **Fine-Tuning e Compilação:** A rede base foi descongelada (`trainable = True`) para permitir a sintonia fina de seus pesos perante os padrões oncológicos. O modelo foi compilado usando o otimizador *Adam* com uma taxa de aprendizado intencionalmente baixa ($1e-4$). Essa escolha é fundamental no *Fine-Tuning* para ajustar os pesos de forma suave, sem destruir o conhecimento estrutural prévio da rede. As métricas alvo escolhidas para a validação clínica foram a Acurácia e a AUC (*Area Under the Curve*).

Executando o modelo

Para executar o modelo, como o conjunto de dados pode ser desbalanceado (número diferente de casos benignos e malignos), calcularemos os pesos das classes para dar mais importância à classe minoritária durante o treinamento. Isso ajuda a evitar que o modelo fique enviesado para a classe majoritária.

Ao executar o modelo, obtivemos os seguintes resultados



Conclusão e Próximos Passos

Ao longo dos nossos testes, o modelo apresentou uma evolução significativa e notável. Inicialmente, enfrentamos desafios com sobreajuste (overfitting) e uma baixa capacidade de generalização, onde o modelo alcançava métricas iniciais fracas (como um AUC próximo a 0.50 e baixa acurácia). Ao refinar nossa abordagem — implementando o aumento da resolução das imagens para 300x300, migrando para uma arquitetura mais profunda (EfficientNetB3), balanceando os pesos das classes (Class Weights) e aplicando um Data Augmentation mais agressivo e voltado para a variabilidade de imagens radiográficas —, conseguimos dar um salto expressivo, alcançando uma Acurácia de aproximadamente 71% e um AUC de 0.78 no conjunto de teste.

Apesar desse grande avanço, a classificação automática de mamografias é um dos problemas mais complexos da visão computacional médica, pois tumores e anomalias benignas muitas vezes compartilham texturas muito similares. Para melhorar ainda mais os resultados no futuro, recomenda-se explorar as seguintes frentes:

Pré-processamento Especializado (Filtros Médicos): Aplicar técnicas como o CLAHE (Contrast Limited Adaptive Histogram Equalization) antes de passar a imagem para a rede, o que ajuda a destacar o contraste de microcalcificações e contornos de nódulos invisíveis a olho nu.

Abordagem Multimodal: A medicina não olha apenas para a imagem. Combinar a rede neural de imagens com os dados tabulares estruturados (idade do paciente, densidade da mama, histórico familiar) pode enriquecer drasticamente a capacidade de decisão do modelo.

Segmentação e Detecção (YOLO/U-Net): Em vez de classificar a imagem inteira, treinar um modelo para desenhar uma máscara exatamente onde a anomalia está localizada, reduzindo o ruído de fundo (tecido saudável) que confunde a rede.

Ensemble e Novas Arquiteturas: Combinar as previsões do EfficientNet com outras arquiteturas modernas, como Vision Transformers (ViT), que são excelentes para conectar o contexto de diferentes áreas da imagem.